Cuantificación bidireccional de temas en proyectos y publicaciones

Fórmulas, procedencia y ejemplo trabajado

Instituto Pulso PUCP — Libro Blanco

10 de octubre de 2026

1. Planteamiento

Cada proyecto o publicación (una *unidad* u) trata de varios temas a la vez, en distinto grado. El equipo pidió responder dos preguntas distintas para el mismo par (unidad, tema):

1. **¿Cuánto de la unidad es este tema?** — si miro solo este proyecto, qué fracción de lo que hace corresponde a este tema.
2. **¿Cuánto del tema aporta la unidad?** — si miro solo este tema, qué fracción de todo lo que lo compone viene de este proyecto.

Estas dos preguntas casi nunca tienen la misma respuesta numérica, y la diferencia depende únicamente del tamaño del tema (§5). No existe una etiqueta corta y estándar para este par de lecturas — se nombran aquí por la pregunta que responden en vez de inventar un término que se prestaría a confusión — pero las matemáticas de abajo sí son estándar (§6).

2. La matriz de afinidad

Todo parte de una matriz de afinidad $w[u, t] \geq 0$: cuánta evidencia hay de que la unidad u trata del tema t. Se construye mezclando dos fuentes, cada una normalizada a que su fila sume 1 antes de mezclarlas:

- **Extracción por LLM** (peso $\alpha = 0.7$ por defecto): un LLM lee el texto de la unidad y devuelve de 1 a 5 temas, cada uno con una cita literal verificada contra el texto y una confianza en $[0, 1]$. Si varios temas extraídos de la misma unidad caen, al normalizar, dentro del mismo tema normalizado, sus confianzas se suman.
- **Similitud de embeddings** (peso $1-\alpha = 0.3$): coseno entre el embedding del texto completo de la unidad y el centroide de cada tema (la media de los embeddings de los temas extraídos que ese agrupamiento reunió). Se recorta antes de usarla — descartar lo que no supera un piso de 0.30, quedarse con los $k = 8$ temas más cercanos y elevar a una potencia $p = 3$ — porque en este corpus el coseno entre dos textos *no* relacionados ronda 0.45, no 0: sin el recorte, toda unidad se repartiría casi por igual entre todos los temas y el coeficiente de partición (§4.1) caería a su mínimo.

Solo la primera fuente tiene evidencia textual directa detrás; la segunda es proximidad semántica del texto completo, no algo que el LLM haya afirmado de esa unidad en particular. Sin la segunda, con solo 2–4 temas extraídos por unidad, la partición resultante es casi nítida en vez de difusa: cada unidad cae en un tema casi al 100 % y la segunda pregunta pierde sentido (ver la corrida `legacy-49` en `docs/cuantificacion_temas.md`).

3. Las dos fórmulas

$$C[u,t] \;=\; \frac{w[u,t]}{\sum_{t'} w[u,t']} \qquad (\text{“cuánto de la unidad es este tema”},\; = P(t \mid u)) \tag{1}$$

Se fija la unidad u y se suma w sobre *todos los temas*: el total de la fila de esa unidad. Todas las $C[u,\cdot]$ de una misma unidad suman 1.

$$E[t] \;=\; \sum_{u} C[u,t] \tag{2}$$

El tamaño del tema en *unidades-equivalentes*: se fija el tema t y se suma C sobre *todas las unidades* — el total de la columna. Como $\sum_u C[u,t]$ ya reparte 100 % de cada unidad entre sus temas, $\sum_t E[t] = N$ (el total de unidades): los tamaños de los temas se pueden sumar sin doble conteo.

$$K[u,t] \;=\; \frac{C[u,t]}{E[t]} \qquad (\text{“cuánto del tema aporta la unidad”},\; = P(u \mid t)) \tag{3}$$

Se divide la misma celda $C[u,t]$ entre el tamaño de su columna. Todas las $K[\cdot,t]$ de un mismo tema suman 1.

Las dos fórmulas comparten la celda $C[u,t]$. Lo único que cambia es la dirección de la suma en el denominador: por fila (a través de temas, para esta unidad) en la primera, por columna (a través de unidades, para este tema) en la segunda. $E[t]$ es, de hecho, esa suma por columna, y es el puente entre las dos: dividir por $E[t]$ es la regla de Bayes escrita al revés — la segunda lectura es la primera corregida por lo grande que sea el tema.

4. Complementos: cuántos cuentan de verdad

$$\text{temas efectivos de } u \;=\; \frac{1}{\sum_t C[u,t]^2} \qquad\qquad \text{unidades efectivas de } t \;=\; \frac{1}{\sum_u K[u,t]^2} \tag{4}$$

El *número efectivo* $1/\sum p^2$ dice cuántas piezas, si todas pesaran igual, producirían la misma concentración que la distribución real. Si diez proyectos aportan 10 % cada uno, salen 10 efectivos; si uno aporta 90 % y los otros nueve 1.1 % cada uno, sale 1.2: dice cuántos cuentan de verdad, no cuántos hay.

4.1. Coeficiente de partición

$$PC \;=\; \frac{1}{N}\sum_{u}\sum_{t} C[u,t]^2 \qquad\qquad PC_{\text{norm}} \;=\; \frac{PC - 1/T}{1 - 1/T} \tag{5}$$

PC vale 1 si cada unidad cae en un único tema (partición nítida) y $1/T$ si se reparte por igual entre los T temas (partición uniforme, sin información). PC crudo depende del número de temas T — un 0.45 con 49 temas y un 0.45 con 121 no significan lo mismo — por eso se reporta PC_{norm} (normalización de Dunn/Backer), comparable entre corridas con distinto T.

PC_{norm}	Interpretación	
> 0.95	partición prácticamente nítida	la contención no aporta nada sobre una asignación simple
0.2 – 0.8	rango informativo	reportar
< 0.05	prácticamente uniforme	revisar el recorte de la similitud

5. Ejemplo trabajado

Proyecto 767, *"Stabilizability with Markov Parameters Partially Known and Metrics of..."*, tema *"Estabilidad estocástica de sistemas singulares con saltos markovianos"*, corrida `full-proj-409`.

Paso 1 — la fila de afinidades de esta unidad (las 8 con valor):

$$0.8876,\ 0.0278,\ 0.0205,\ 0.0179,\ 0.0124,\ 0.0120,\ 0.0115,\ 0.0103 \qquad \sum = 1.0000$$

Paso 2 — contención:

$$C[u,t] = \frac{0.8876}{1.0000} = 0.8876 \;\rightarrow\; 88.8\ \%$$

El 88.8 % de lo que trata este proyecto es este tema.

Paso 3 — tamaño del tema: sumando esa misma columna sobre las 409 unidades del dominio, el tema recibe fracciones de 17 proyectos distintos y acumula

$$E[t] = 4.48 \text{ unidades-equivalentes.}$$

Vale 4.48 proyectos enteros, aunque lo rocen 17.

Paso 4 — contribución:

$$K[u,t] = \frac{C[u,t]}{E[t]} = \frac{0.8876}{4.48} = 0.1982 \;\rightarrow\; 19.8\ \%$$

Este proyecto es, él solo, el 19.8 % de todo el tema.

El mismo $w[u,t] = 0.8876$ produce 88.8 % o 19.8 % según contra qué total se mida: la fila del proyecto, o la columna del tema. Si el tema fuera del tamaño del tema más grande de esta corrida (20.3 unidades-equivalentes, sostenido por 107 proyectos), la misma contención del 88.8 % se traduciría en apenas un 4.4 % de contribución — por eso las dos preguntas hacen falta por separado: preguntar "¿cuánto pesa esta unidad en este tema?" sin decir en qué dirección no tiene una sola respuesta.

6. De dónde sale esto

- **La matriz de pertenencia difusa.** Que una unidad pertenezca a varios temas a la vez, en grados que suman 1, es una *partición difusa*: el objeto central del agrupamiento difuso (*fuzzy c-means*, Bezdek, 1981). De ahí viene también el coeficiente de partición que sugirió el profesor, que no es el número por celda sino un índice de validez del conjunto completo.
- **Las dos direcciones.** Son probabilidad condicionada elemental sobre una distribución conjunta $P(u,t) \propto w[u,t]$, unidas por la regla de Bayes. $P(t \mid u)$ es, además, lo mismo que devuelve un modelo de tópicos tipo LDA como distribución tema-documento; la novedad aquí no es esa mitad, sino publicar también la otra.
- **Las unidades-equivalentes.** Son *conteo fraccionado* (*fractional counting*), la práctica estándar en bibliometría para repartir el crédito de una publicación entre sus autores o instituciones en vez de contarla entera para cada uno. Aquí se reparte entre temas en vez de entre autores.
- **El número efectivo** $1/\sum p^2$ se reinventa en todas partes con el mismo nombre distinto: inverso del índice de Simpson en ecología, inverso del índice de Herfindahl–Hirschman en economía de la competencia, "número efectivo de partidos" en ciencia política.

7. Reproducibilidad

Todas las cifras de este documento salen de la corrida `full-proj-409` del dominio `projects` (409 proyectos, filtrados por el universo mínimo vigente entonces: cerrado y 2010+, con `title`, `knowledge_area` y al menos una línea de investigación). Desde el 2026-09-30 el atlas publicado usa otra corrida, `full-proj-646` (criterio `title` + `cris_abstract`), así que los números del ejemplo no coinciden con lo que muestra el atlas hoy; las fórmulas son las mismas. Fórmulas implementadas en `scripts/lib/lb_membership.py`; corren sobre Amazon Bedrock (`Claude Sonnet 5` para extracción y nombrado, `cohere.embed-multilingual-v3` para embeddings) y se guardan en PostgreSQL con `pgvector` en Amazon RDS.